

機器學習期末報告

基於腦電圖信號與 ML 設計一個「主觀認知衰退」與「輕度認知障礙」之 AI 鑑別診斷方法

組員：李惟哲(314514040)、馬珮薰(314512045)

1. 簡介

主觀認知衰退 (SCD) 和輕度認知障礙 (MCI) 是介於正常老化與失智症之間的兩個重要階段，最大的差異在於客觀認知測試的表現和記憶力衰退對日常生活功能的影響，目前臨床上的區分方式主要依賴詢問病史、自我報告問卷 (如 SCD-Q) 以及神經心理學測驗 (如 MMSE, MoCA) 來區分。

SCD 的定義需要患者主觀認定認知力衰退，但客觀測試結果還保持在正常範圍內，SCD 在老年人口中非常常見，盛行率或高達 50% 以上 [1]，通常不需要醫療層級的處置，以積極的生活方式 (例如運動、健康飲食) 來延緩衰退狀況即可。另一方面，MCI 的定義則更加明確，需要在標準測試中低於常模 1 至 1.5 個標準差 [2, 4, 5]，然仍能維持自主正常生活，這也是 MCI 與失智症的最大差別。MCI 的醫療處置包括積極的血管風險因子管理、透過生物標記確認潛在病因等，盛行率約為 10% 至 20% [3]。

區分 SCD 與 MCI 是非常重要的，因為這兩者代表著健康到確認疾病發生的中間地帶，醫療處置的方向完全不同，SCD 可以及早預防衰退，MCI 則是需要減緩疾病進程。同時，迅速區分 SCD 和 MCI 的能力也有助於減緩醫療系統的負擔，把寶貴的醫療資源留給真正需要進到療程的病人。

由於缺乏專門用於區分 SCD 與 MCI 的獨立診斷儀器，現有的高階儀器 (MRI/PEI) 是作為診斷用的輔助儀器使用，其中 MRI 在 MCI 階段，醫師可觀察海馬迴 (hippocampus) 是否萎縮 [5]，相對來說在 SCD 階段，大腦結構改變細微，因此不易區分正常與老化的差異 [6]。而 PET 則可檢測大腦中的類澱粉蛋白 (Amyloid) 與 Tau 蛋白沉積，雖然精確但成本高昂 [4]；而傳統的腦波儀 (EEG)，雖普及但缺乏足夠的解析度與自動化分析能力來識別早期認知衰退 [7]。

除了診斷器材之外，目前的診斷方式還具有以下缺點，如主觀性與偏差，SCD 的診斷高度仰賴患者的主觀報告，容易受到焦慮、憂鬱或是人格特質的影響 [4, 5]。天花板效應 (Ceiling Effect) [5]，即傳統測驗 (如MMSE) 對教育程度較高者不夠敏感 [4]，這類型患者即使大腦有病變，仍可能考出高分，導致偽陰性 (將 MCI 誤判為 SCD 或正常)；PET 掃描或腦脊髓液 (CSF) 檢測可提供精確生物標記，但價格昂貴且具侵入性，不適合大規模篩檢 [6, 7]。最後，SCD 與 MCI 界線模糊，這兩者在大腦功能與結構改變上具有重疊性，僅靠量表難以精確區分 [5, 6]。

若利用 EGG 搭配 ML 開發 AI 鑑別診斷系統，對於病人能提供非侵入式、低成本且快速的篩檢方式，對於醫師來說該系統能夠提供客觀的生理指標，透過 EGG 及 AI 反映出大腦皮質的突觸功能障礙，輔助醫生作出更準確的早期診斷。

目前市場上尚未有通過 FDA 許可、專門利用「EEG 結合 AI」來區分 SCD 與 MCI 的商業化產品。但已有核准的 AI 產品用於 MRI 影像分析或預後預測，輔助診斷或預測阿茲海默症及其他失智症，如 BrainSee (Darmiyan) 利用 MRI 影像結合認知評分，預測 MCI 患者特定時間內發展為阿茲海默症的風險 [8]。

2. 文獻回顧

來自上海交通大學 Yue Ding 教授的研究團隊 [9] 嘗試利用 EEG 訊號區分正常認知 (NC)、MCI 和 AD 患者，從 301 名受試者 (113 NC, 116 MCI, 72 AD) 收集了休息狀態下的 EEG 數據，並使用了 62 個通道進行採樣。研究提取了包含頻譜特徵 (例如 Band Power Ratio)、複雜度 (例如多尺度熵) 和功能連接性 (例如相關係數) 等的 7,400 個特徵，並使用主成分分析 (PCA) 進行資料降維。這項研究比較了 LDA、SVM 和多種集成樹模型等共 9 種分類器，並使用 5 摺交叉驗證評估性能。實驗結果顯示將 EGG 訊號加入分類器後，9 種分類器的表現皆優於只使用統計數據的經驗分類方法。在區分 AD vs. NC 任務中，最佳 AUC 達到 80.08% (由 Random Forest 達成)，最高 ACC 為 72.43% (由 RUS boosting 達成)。區分 AD vs. MCI 的最佳 AUC 為 70.82%，ACC 為 69.11% (均由 RUS boosting 達成)。顯示了使用休息狀態 EEG 進行 AD 分類篩查的可行性。

另一組來自西班牙格拉納達大學 Eduardo Perez-Valero 教授的研究團隊 [10] 也有相似的研究，目的同為區分 NC、MCI、AD，不過是以多類別分類的方式進行。研究共納入了 134 名受試者 (36 位 NC, 40 位 MCI, 58 位 AD)，同樣提取休息狀態下的 EGG 數據，差別在於特徵提取。這組團隊提取了包

括相對功率頻譜密度 (RPSD)、相位鎖定值 (PLV) 功能連接性、熵和振幅調製在內的四類特徵，並使用 Random Forest 的 MDI 指標，從 12,080 個原始特徵中選取最相關的 500 個特徵。

分類器選用了搭配高斯核的 SVM，使用 10 摺交叉驗證來評估模型性能。在多類別分類 (NC vs. MCI vs. AD) 任務中取得了 87.31% 的準確度。在二元分類中，AD vs. NC 的 AUC 高達 97.4%，同樣展現出 EGG 用於 AD 早期篩檢的能力。然而，這兩項研究皆未使用獨立測試集，因此模型的泛化能力仍需進一步使用外部資料作驗證。

再來是來自韓國中央大學醫院的 Min-jae Kim 等人研究團隊 [11]，利用自行建構的 CAUEEG 臨床資料集，開發一套低成本且非侵入性的自動化篩檢系統。研究設計了兩個核心任務：針對「正常、輕度認知障礙 (MCI) 與失智症」的三分類任務，以及針對「正常與異常 (包含其他腦部疾病)」的二分類任務。資料集包含來自 1155 位患者的 1379 筆 EEG 訊號，採樣於清醒臥床的休息狀態下的受試者，使用國際 10-20 系統的 19 個通道進行記錄。

該研究提出 CEEDNet 架構，這是一種端對端的深度學習方法，沒有特徵提取與篩選步驟，直接讓模型從原始訊號或頻譜圖中學習特徵。為了確保評估的臨床可靠性，研究設有獨立的測試集，將資料劃分為訓練、驗證與測試集 (約 8:1:1)。最終，透過多個模型的集成，在三分類任務中達到 74.66% 的準確率 (ROC-AUC 0.9)，在二分類任務中則達到 79.16% 的準確率 (ROC-AUC 0.86)。

第四篇來自義大利的多個學術與醫療機構共同合作提出 [12]，利用深度學習技術區分 SCD 與 MCI 患者。研究團隊收集了 101 位受試者 (56 位 SCD 和 45 位 MCI) 閉眼休息狀態的 EEG 資料。在數據處理上，研究者從原始的 64 個通道中篩選並保留了 19 個通道，不過這份研究並未使用特徵篩選，而是建立了一個基於 Transformer 架構的模型，直接處理預處理且切片過的 EEG 訊號，利用模型的 Self-Attention 機制來自動學習來給予適合做為特徵的訊號片段權重。性能評估方面，團隊採用 5 摺交叉驗證來訓練與驗證模型，並特別保留 20% 的受試者作為獨立測試集。最終的最佳模型在獨立測試集上達到了 65.7% 的受試者分類準確率。

最後一篇也是來自義大利的學術與醫療機構 [6]，設計了基於 Attention-based 的深度學習模型，用於 SCD 與 MCI 的二元分類問題，以及 NC、SCD 與 MCI 的三分類問題。資料來自 118 位受試者 (17 位健康對照 NC、56 位 SCD、45 位 MCI)，EEG 數據均在休息狀態閉眼條件下收集。研究從原始 64 通道中選取 19 個通道，並透過濾波器提取 Delta、Theta、

Alpha、Beta 等頻段作為輸入，採用 End-to-End 的 Transformer 架構學習訊號的時間依賴性。性能評估的部分，採用留一受試者交叉驗證法 (LOSOVC) 確保模型的泛化能力。在研究的結果中，Delta 頻段在 SCD vs MCI 分類表現最佳，準確率達 76.2%，AUC 為 80.7%，而 Theta 頻段在三類分類中表現最好，準確率為 54.2%。不過研究沒有使用獨立測試集，主要原因是受試者樣本數較少，若硬性切割獨立測試集會導致訓練數據不足。因此，研究採用 LOSOCV (Leave-One-Subject-Out Cross-Validation)，每次只選用一個受試者的資料用作驗證，其餘的用於訓練模型。作者認為這個方法在有限數據下，仍能有效評估模型對「未知受試者」的泛化能力，但也承認未來如果能取得更大的受試者群體，將有助於進一步驗證模型的有效性。

從上述的先前研究中，可以確認 EEG 訊號足以作為分類 SCD、MCI 等認知障礙疾病的特徵，並可透過機器學習亦或是深度學習技術實現自動化檢測。兩篇主要研究 SCD 與 MCI 分類的文獻 [6, 12] 更指出，使用 EEG 特徵區分 SCD 與輕度認知障礙 MCI 的關鍵在於大腦振盪活動中的「廣泛性變慢 (diffuse slowing)」神經退化現象。更詳細的說，低頻波段是 EEG 特徵的重要之處，MCI 患者相較於 SCD 患者，在 Delta (0.1–4 Hz) 與 Theta (4–8 Hz) 頻段的功率增加 [6]，伴隨 Alpha (8–12 Hz) 功率降低 [12]，顯現了頻譜能量由高頻向低頻轉移的特性。此外，也透過 Transformer 模型的自注意力機制進一步發現這種「低頻增強、高頻減弱」的特徵模式是集中於額葉、中央區、頂葉與顳枕葉等特定解剖區域 [12]，針對這些關鍵腦區進行分析才能辨別出 SCD 發展至 MCI 過程中的細微神經變化。

表一、不同研究之研究異同比較表。

參考文獻	目標	EEG 條件 (腦波擷取狀態/電極數目/受試者人數)	腦波特徵/是否有 feature selection	分類器	性能評估方法、分類率、有無 Independent test data ?
[9]	正常認知/ MCI/ AD 分類	休息狀態(resting state)/62個EEG通道/301位受試者 (NC:113, MCI:116, AD: 72)	spectral features, complexity, and functional connectivity/有	比較9種分類器。包含(LDA)、邏輯迴歸、樸素貝葉斯、KNN、SVM、以及 Random Forest、GBDT、XGBoost 和 RUS boosting	5-fold CV/ AD vs. MCI=70.8%/無
[10]	正常認知/ MCI/ AD 分類	休息狀態(Resting state)/20顆電極/ 36 NC、40 MCI 和 58 AD 配上	RPSD, Functional Connectivity, Entropy features, Amplitude Modulation /有	SVM 配上 Gaussian kernel	10-fold CV/ SVM=87.31% (多類別分類) /無
[11]	正常認知/	休息狀態(Resting	End-to-end Learning		Accuracy, ROC-

	MCI/ 失智症三分類	state)/19 個 EEG 通道/ 1155 位患者的 1187 筆 EEG 錄音(Normal:459, MCI:417, Dementia:311)	(1D raw signals 或 2D spectral images) / 無	比較15種分類器。包含 CEEDNet Ensemble (結合 1D/2D CNN 與 ViT 等模型)；亦比較 KNN、Random Forest、Linear SVM、leracitano-CNN。	AUC / Acc = 74.66%, ROC-AUC = 0.90 / 有 (split 訓練、驗證與測試約 8:1:1)
	正常認知/ 異常(包含 MCI與失智症)二分類	休息狀態(Resting state)/19 個 EEG 通道/ 1155 位患者的 1379 筆 EEG 錄音 (Normal:459, Abnormal:920)			Accuracy, ROC-AUC / Acc = 79.16%, ROC-AUC = 0.86 / 有(同上)
[12]	SCD/MCI 分類	休息狀態 (Resting-state)/ 19 個 EEG 通道 /101 位患者 (56 SCD, 45 MCI)	使用原始訊號切片 (Epochs) 經由 Patch Embedding 輸入，無特徵萃取 / 無	Transformer	5-fold CV/Subject Accuracy: 65.7%; Epoch Accuracy: 65.4%/有 (train:test = 8:2)
[6]	SCD/MCI 分類	休息狀態 (Resting-state)/ 19 個 EEG 通道/ 118 人 (HC:17、	End-to-End 深度學習 (Raw EEG 輸入)/無	Transformer	LOSOCV/SCD vs MCI (Delta band): Accuracy 76.2%, AUC 0.807/無
	HC/SCD/MCI 三分類	SCD:56、MCI:45)			LOSOCV / HC vs SCD vs MCI (Theta band): Accuracy 54.2% / 無

3. 議題與突破點

在 EEG 結合 AI 用於 SCI 與 MCI 分類的這項研究題目中，我們從先前的研究中注意到以下幾個尚待改進之處：腦波特徵重疊程度高，導致模型的分類邊界模糊；資料數據不足，分類模型沒有足夠的參考畫出最佳的決策邊界，數據不足也導致模型驗證缺乏獨立測試資料集，模型的泛化性無從衡量；使用 Transformer 模型的詮釋性不足，無法以神經科學判斷模型捕捉到的特徵是否符合醫學理論。

我們認為目前這個題目最需要改進的部分是資料端的不足，在較有指標性的研究 [6,12] 中樣本規模多侷限在百人左右，對於 Transformer 這種依賴大數據的模型是遠遠不夠，會產生 overfitting 的現象，並且由於 SCD 與 MCI 並非特徵空間中區分非常開的兩個類別，如果特徵沿用先前研究的選擇，則我們需要非常大量的資料幫助我們理解兩種類別在特徵空間中是如

何重疊的、重疊部分多大。而針對處在灰色地帶的那些資料，我們或許能將其歸類為 MCI 高風險族群，將我們認為可能已步入 MCI 階段的病人轉至醫院做更詳細的檢查。

然而，為了能將研究推向新高度，在分類率上必須取得更大的進展，此時我們認為增加輸入的特徵是非常重要的，先前已有的研究皆以靜態量測下的 EEG 作為原始資料，這引發了我們的好奇。從比較直觀的角度來看，要檢測認知能力的話使用正在思考時的腦波訊號應該是更具有代表性的，採用靜態放空時的腦波數據，或許是為了統一量測標準、確立資料在個體間一致性的無奈之舉。因此，在能確保量測標準一致的前提下，我們認為或許能發展綜合靜態休息、情緒感知、邏輯思考、認知測驗等四種不同情境下的腦波量測標準，這將使我們在原始資料端有更多的資訊，也更能從受試者的不同腦波狀態判斷認知能力的變化。

另一項可採取的解決方向是使用數據增強 (Data Augmentation) 與遷移學習 (Transfer Learning)。可以採用滑動視窗 (Sliding Window) 的方法，將長段腦波切成數千個重疊的短片段進行訓練，並在測試階段採用多數決的機制來過濾雜訊，將同屬一個腦波訊號的短片分別放入模型測試，以出現次數高的預測類別做為最終的預測結果。其次，引入遷移學習的策略，先利用大型公開的腦波數據庫(如 TUH Corpus) 對模型進行預訓練，讓模型去學習通用的腦波特徵結構，再針對 SCD/MCI 小樣本進行微調，來提升模型在小數據上的表現與穩定性。

模型使用方面，由於當前使用 Transformer 架構執行 SCD 與 MCI 分類是屬於黑盒子，臨床醫生無法根據結果解釋原因。目前 Transformer 的相關研究雖然能呈現 Attention score 的熱力圖來理解哪些特徵較為重要[12]，但缺乏對生理意義的解讀，無法解釋究竟是哪一個頻段出現異常。因此我們可以利用演算法(如 CVAE 條件變分自編碼器) 讓模型學習大量數據分布，繪製出過濾雜訊後的 SCD 與 MCI 標準腦波，這兩組標準波型排除了受試者個別差異，代表疾病最根本的生理特徵。透過將這兩組標準腦波互相，就能找出 SCD 惡化成 MCI 的生物標記，例如原先 SCD 波形中 Alpha 波段的出現一定能量，但在 MCI 的波型中，這股能量消失且轉移到低頻區 (Theta/Delta)。這方法可以顯現原本被掩蓋住的微小病理特徵，並把數學模型轉換成視覺化的證據。

最後，當前分析流程需要依賴人工處理(如 ICA 去除偽影、手動特徵篩選) 的問題，因此建立一個端對端的自動化分析模型來提供高效率且客觀的方法也能提升整體系統的運行效率。透過在神經網路前加上一個具備物理

規範的參數化卷積層 (如 SincNet)，限制卷積核符合帶通濾波器的物理形狀，讓模型在練過程中僅針對截止頻率去學習。在訓練過程中，模型能根據損失函數自動調整濾波參數，去學習如何去除雜訊並找出最具辨識度的片段 (如自動鎖定 4-8Hz 的 Theta 波段)。

表二、突破點與解決方案一覽表

問題描述	可行的解決方向	解決方法
SCD 與 MCI 特徵重疊與邊界模糊	讓大腦在不同狀態下量測腦波	量測靜態休息、情緒感知、邏輯思考、認知測驗下的腦波
數據量不足	提升數據量	1.數據增強：採用滑動視窗增加數據量，並利用多數決來過濾雜訊 2.遷移學習：利用公開腦波資訊對模型進行預訓練
Transformer 可解釋性不足	建立生成標準標準波形的模型	利用CAVE演算法讓模型學習大量數據分布，繪製排除受試者個別差異的 SCD 與 MCI 標準腦波，代表疾病最根本的生理特徵。
生物標記自動化	建立自動化分析模型	在神經網路前加SincNet卷積層，限制卷積核符合帶通濾波器的物理形狀，讓模型在練過程中僅針對截止頻率去學習。

4. 提出之方法



圖一、AI 模型架構設計、運作流程。

這份研究的核心目標是建立一個高準確率並能具有神經科學詮釋性的 AI 診斷系統，以先前的研究技術為參考，開發一套更為先進及準確的 AI 分類模型，使用 EEG 腦波訊號快速鑑別 SCD 與 MCI 兩項阿茲海默症的前期病症。改良後的整體架構如下：首先是引入認知負載的腦波擷取，接著以數據擴增的手法應對樣本不足的問題，而後是端到端的資料前處理與特徵提取，並隨之生成預測結果，最後是以模型訓練的成果建立具可解釋性的生成模組，將模型的數學權重轉化為具體的生物標記。

首先，在腦波擷取階段，這套系統將引入了「認知負載 (Cognitive Load)」機制以強化特徵的豐富度，以求提升分類準確率。不同於傳統研究多採用的靜止休息狀態紀錄腦波，我們希望能讓受試者在執行類似於 R4Alz 的測驗。根據 Poptsi 等人 (R4Alz-Revised) 的研究指出 [4]，SCD 患者在靜止休息狀態下能透過神經代償機制 (Neural Compensation) 維持看似正常的臨床表象；唯有施加一定程度的認知負載，使其補償機制因不堪負荷而失效，隱藏在波形中的異常模式才會顯露。因此我們將設計一共通標準的系列測驗，像是準備統一的影片片段，受試者要根據影片內容推估影片中的情緒狀態，或是執行經典的斯特魯普效應 (Stroop Effect)，在字卡上用紅色印出「藍色」的字樣，而受試者要回答出真正的顏色。讓受試者在簡單的任務中用盡大腦的力氣，並收集此時的腦波數據，我們預估這種做法能改善 SCD 與 MCI 之間「特徵重疊」的難題，從源頭提升診斷的敏感度。

接著，針對臨床醫療數據普遍面臨的小樣本問題，本系統導入了數據擴增 (Data Augmentation) 流程。我們參考 Sibilano [6] 的策略，增加每位受試者的腦波紀錄時長，而後我們採用了「重疊滑動視窗 (Overlapping Sliding Window)」技術隊員使樣本作切片處理，設定視窗長度為 4 秒，並配置 50% 的重疊率 (Stride = 2s)。透過此項技術，即便在受試者人數受限的臨床場景下 (如 $N=100$)，我們仍能將原始資料擴增為大型資料樣本。因為同一位受試者即使在相同的靜止休息狀態下，前後的腦波波型也不會相同，因此我們相信此舉將能有效抑制深度學習模型常見的 Overfitting 現象，同時能促使模型學習到單一受試者隨著時間不同而會產生的腦波波型變化，也就是能夠忽視數據噪音，掌握真正與分類相關的特徵。

再來進行端對端資料前處理與特徵提取，參考文獻 [13] 在神經網路的最前端加上一層 SincNet 參數化卷積層，取代需要人工判讀的 ICA 去除偽影流程，並在後面加上 Transformer encoder。不同於傳統抽象且難以解釋的權重，SincNet 限制其第一層卷積核為參數化的 Sinc 函數。這使得模型僅需學習兩個具有物理意義的參數，低頻截止頻率 (f_1) 與高頻截止頻率 (f_2)，將神

經網絡轉化為一組可學習的帶通濾波器，根據 [13] 其濾波器的中心頻率會自動收斂至對分類任務最具辨識力的頻段（如人聲的基頻）。將此概念移至 EEG 分析，我們預期模型的濾波層將自動鎖定與 SCD/MCI 相關的頻段（如 4-8Hz 的 Theta 波）。

再來為最佳特徵選取與分類決策。Transformer 輸出的特徵向量將通過多層感知機（MLP）進行最終的機率運算。此階段模型已內化了從濾波器參數到時間序列權重的最佳特徵組合，系統將依據計算出的機率值與預設閾值，將受試者精確分類為 SCD 或 MCI。

最後，為了賦予模型臨床的可信度，平行建立了一條可解釋性路徑，透過繪製過濾個體差異後的SCD與MCI標準腦波圖，透過對比這兩組標準波型可以觀察到能量如何從高頻區遷移到低頻區。為了精確生成 SCD 與 MCI 的標準原型波型，在模型與可解釋性方面，可透過繪製過濾個體差異後的SCD與MCI標準腦波圖，透過對比這兩組標準波型可以觀察到能量如何從高頻區遷移到低頻區。為了精確產生 SCD 與 MCI 的標準原型波型，可以採用 Conditional Variational Autoencoder (CVAE) 結合 Transformer 架構。參考[14]在處理高維光譜數據的方法，我們將疾病診斷標籤作為條件約束引入潛在空間，CVAE 能有效提取出具備高鑑別度的深層特徵。我們利用此特性計算潛在空間中的類別質心，作為代表該疾病的原型特徵，使模型能夠學習到類別特定的數據分布。這種方法有效過濾了個別受試者的隨機雜訊，讓我們能透過控制條件變數，精準合成出 SCD 或 MCI 頻譜特徵。將抽象的數學特徵轉化為具備生理意義的視覺證據，為臨床診斷提供了可追蹤的生物標記。

5. NSDB 分析

N (needs) SCD與MCI特徵重疊 目前腦波分析需靠人工預處理 模型可解釋性不足	S (solutions) 透過認知任務監測腦波 引入SincNet做濾波，將流程自動化 用CVAE提升模型可解釋性
D (differentiation) 資料由被動靜態轉為主動動態 從人工預處理轉向物理約束的學習 從注意力熱圖[12]轉為原型差異分析	B (benefits) 提升臨床判讀信心 易用性提升 解決小樣本的瓶頸

參考文獻

- [1] The prevalence of subjective cognitive decline in the general population: A systematic review and meta-analysis
- [2] Practice parameter: Early detection of dementia: Mild cognitive impairment (an evidence-based review). Report of the Quality Standards Subcommittee of the American Academy of Neurology
- [3] The diagnosis of mild cognitive impairment due to Alzheimer's disease: recommendations from the National Institute on Aging-Alzheimer's Association workgroups on diagnostic guidelines for Alzheimer's disease
- [4] Poptsi, E., Moraitou, D., Tsardoulis, E., Symeonidis, A. L., Papaliagkas, V., & Tsolaki, M. (2023). R4Alz-Revised: A Tool Able to Strongly Discriminate 'Subjective Cognitive Decline' from Healthy Cognition and 'Minor Neurocognitive Disorder'. *Diagnostics*, 13(3), 338.
- [5] Chiu SI, Fan LY, Lin CH, Chen TF, Lim WS, Jang JR, Chiu MJ. Machine Learning-Based Classification of Subjective Cognitive Decline, Mild Cognitive Impairment, and Alzheimer's Dementia Using Neuroimage and Plasma Biomarkers. *ACS Chem Neurosci*. 2022 Dec 7;13(23):3263-3270. doi: 10.1021/acchemneuro.2c00255. Epub 2022 Nov 15. PMID: 36378559.
- [6] Sibilano E, Brunetti A, Buongiorno D, Lassi M, Grippo A, Bessi V, Micera S, Mazzoni A, Bevilacqua V. An attention-based deep learning approach for the classification of subjective cognitive decline and mild cognitive impairment using resting-state EEG. *J Neural Eng*. 2023 Feb 17;20(1). doi: 10.1088/1741-2552/acb96e. PMID: 36745929.
- [7] Michael Lassi, Carlo Fabbiani, Salvatore Mazzeo, Rachele Burali, Alberto Arturo Vergani, Giulia Giacomucci, Valentina Moschini, Carmen Morinelli, Filippo Emiliani, Maenia Scarpino, Silvia Bagnoli, Assunta Ingannato, Benedetta Nacmias, Sonia Padiglioni, Silvestro Micera, Sandro Sorbi, Antonello Grippo, Valentina Bessi, Alberto Mazzoni. Degradation of EEG microstates patterns in subjective cognitive decline and mild cognitive impairment: Early biomarkers along the Alzheimer's Disease continuum?, *NeuroImage: Clinical*, Volume 38, 2023, 103407, ISSN 2213-1582,
- [8] <https://www.accessdata.fda.gov/scripts/cdrh/cfdocs/cfPCD/classification.cfm?ID=QWT>
- [9] Yue Ding, Yinxue Chu, Meng Liu, Zhenhua Ling, Shijin Wang, Xin Li, Yunxia Li. Fully automated discrimination of Alzheimer's disease using resting-state electroencephalography signals. *Quantitative Imaging in Medicine and Surgery*, Vol 12, No 2, Feb, 2022
- [10] Eduardo Perez-Valero, Miguel Ángel Lopez-Gordo, Christian Morillas Gutiérrez, Ismael Carrera-Muñoz, Rosa M. Vilchez-Carrillo. A self-driven approach for multi-class discrimination in Alzheimer's disease based on wearable EEG. *Computer Methods and Programs in Biomedicine*, Volume 220, June 2022, 106841.
- [11] Min-jae Kim, Young Chul Youn, Joonki Paik. Deep learning-based EEG analysis to classify normal, mild cognitive impairment, and dementia: Algorithms and dataset. *NeuroImage*, Volume 272, 2023, 120054, ISSN 1053-8119.
- [12] Sibilano E, Buongiorno D, Lassi M, Grippo A, Bessi V, Sorbi S, Mazzoni A, Bevilacqua V, Brunetti A. Understanding the Role of Self-Attention in a Transformer Model for the

Discrimination of SCD From MCI Using Resting-State EEG. IEEE J Biomed Health Inform. 2024 Jun;28(6):3422-3433. doi: 10.1109/JBHI.2024.3390606. Epub 2024 Jun 6. PMID: 38635390.

- [13] M. Ravanelli and Y. Bengio, "Speaker Recognition from Raw Waveform with SincNet," 2018 IEEE Spoken Language Technology Workshop (SLT), Athens, Greece, 2018, pp. 1021-1028, doi: 10.1109/SLT.2018.8639585.
- [14] X. Wang, K. Tan, Q. Du, Y. Chen and P. Du, "CVA2E: A Conditional Variational Autoencoder With an Adversarial Training Process for Hyperspectral Imagery Classification," in IEEE Transactions on Geoscience and Remote Sensing, vol. 58, no. 8, pp. 5676-5692, Aug. 2020, doi: 10.1109/TGRS.2020.2968304.