

設計流程

1. Data

從 sklearn 裡的 dataset 用 load_iris 匯入 data，共 150 筆資料，分三類 (C1:Setosa, C2:Versicolor, C3:Virginica)，及四個特徵(SL、SW、PL、PW)。

2. 分類器

- K-NN(K-nearest neighbor)：對於測試樣本 x ，計算其與 training set 中所有樣本 $(x_i, i = 1, 2, \dots, N)$ 的距離(即 $\|x_i - x\|, i = 1, 2, \dots, N$)，接著找出距離最小的 K 個 training data points，根據這些樣本的標籤進行多數決投票，來預測 x 的類別。
- LDA(linear discriminant analysis)：在空間中，找到一個超平面把不同類別分開
決策函數 $D(x) = \mathbf{w}^T \mathbf{x} + b$ ， $\mathbf{w}$ 為超平面的權重向量， b 為超平面的偏差值。

3. 評估(by 2-fold cross validation)

Fold1: 各類前 25 筆資料作為 training set，後 25 筆資料作為 test set。

Fold2: 各類前 25 筆資料作為 test set，後 25 筆資料作為 training set。

最後得到的準確率為兩個 fold 所得到的準確率的平均。

(A)Binary classification

在不同特徵組合下，使用不同分類器，建立了三組獨立的二元分類問題，在每個任務中，模型僅使用其對應的兩類資料進行訓練與測試。取得不同特徵組合下，各分類器的準確率變化。

(1)四個特徵皆採用

	1-NN	3-NN	LDA
C1 vs C2	1.00	1.00	1.00
C1 vs C3	1.00	1.00	1.00
C2 vs C3	0.92	0.91	0.94

(2)PL 與 PW 兩個特徵

	1-NN	3-NN	LDA
C1 vs C2	1.00	1.00	1.00
C1 vs C3	1.00	1.00	1.00
C2 vs C3	0.93	0.93	0.94

(3)SL 與 SW 兩個特徵

	1-NN	3-NN	LDA
C1 vs C2	0.99	0.99	0.99
C1 vs C3	0.98	0.99	0.99
C2 vs C3	0.56	0.65	0.72

僅使用花瓣的特徵(PL+PW)的準確率皆高於使用花萼的特徵(SL+SW)，代表 Iris 的花瓣尺寸有更明顯得特徵，花萼特徵則在不同品種下有較大的重疊。

C1 vs C2 以及 C1 vs C3 分類準確率皆接近 100%，而 C2 vs C3 時的準確率較低，表示 C2、C3 在特徵上最為相似。

特徵組合 All 與 PL+PW 的準確率非常相近，但在 c2 vs c3 的組合下可發現 k-NN 上 All 的準確率還是低了一點，推測花萼幾乎沒有提供有效資訊，可視為雜訊，對於 k-NN 基於距離的演算法產生干擾。

(B) 3-class classification


使用全部資料(C1, C2 & C3)進行 training 與 test，k-NN 直接處理多類別問題，LDA 則使用 one-against-one+多數決的方法，故會先執行三個二元分類器，並對 data point 進行投票來預測結果。最後得到單一的整體準確率。

	Accuracy
1-NN	0.947
3-NN	0.940
LDA(one-against-one + vote)	0.960

LDA 採用 OAO+多數決投票，在 c2 vs c3 較難準確二元分類的組合，綜合投票下仍占有優勢，故推測其為準確率最高的原因。

(C)

繪製 ROC 曲線是透過系統性地掃描所有可能的 decision threshold。在每一個 threshold 下，模型都會產生一組新的預測結果，並由此計算出一對對應的偽陽性率 (FPR) 與真陽性率 (TPR)。將所有 threshold 產生的 (FPR, TPR) 數對在圖上描點並連接，便構成 ROC 曲線，以評估 LDA 在不同操作點上的性能。



ROC 曲線(藍色)非常貼近左上角，代表能在維持極低 FRA 的同時可以達到非常高的 TRA。AUC 值為 0.994，接近 1.0，代表 LDA 分類器在使用四個特徵時，對於區分 C2(正常)與 C3(異常)有相當好的能力。

(D 考慮到 false negative(漏掉真正的異常->影響良率)的成本高於 false positive(判正常的為異常->可能需要停機維護)的成本，以 ROC 曲線為依據，調整 LDA 的 decision threshold，滿足可接受的最低 TPR，接著在 ROC 曲線上尋找滿足此條件下的最低 FPR，找到最佳操作點，並採用對應的 threshold。優先確保不存在潛在瑕疵，才能有效阻止瑕疵品流入市場，進而提升公司產品的良率並減少維護等所需的隱性成本。