

Quadratic problem solver: cvxopt (適合小規模且密集的 data set)

Part 1: Linear SVM

```
C = 1.0
Alpha sum = 14.4
alpha =
[1.      0.0667 1.      0.      1.      0.      1.      0.      0.      0.
 0.      0.      0.      1.      0.      0.      0.0667 0.      0.0667 0.
 1.      0.      1.      0.      0.      0.      1.      0.      0.      0.
 0.      1.      0.      0.      0.      1.      0.2    0.      1.      0.
 0.      0.      0.      0.      1.      0.      1.      0.      1.      0. ]
b* = 10.5511
CR = 94.0%
```

```
C = 10.0
Alpha sum = 75.9998
alpha =
[ 0.      0.      9.      0.      0.      0.      10.     0.      0.
 0.      0.      0.      0.      0.      0.      0.      0.      0.
 0.      0.      10.     0.      9.      0.      0.      0.      7.9999
 0.      0.      0.      0.      10.     0.      0.      0.      0.
 0.      0.      0.      0.      0.      0.      0.      0.      10.
 0.      0.      0.      10.     0.      ]
b* = 15.1398
CR = 96.0%
```

```
C = 100.0
Alpha sum = 577.7748
alpha =
[ 0.      0.0056 44.4299 0.      0.0076 0.      100.     0.
 0.      0.      0.      0.0031 0.      0.      0.      0.
 0.0056 0.      0.0056 0.      100.     0.      44.4299 0.
 0.      0.      0.      0.      0.0038 0.      0.      100.
 0.0017 0.0028 0.      0.      0.      0.      0.      0.
 0.      0.0045 0.      0.      100.     0.      0.      0.
 88.8746 0.      ]
b* = 11.1075
CR = 92.0%
```

Linear SVM	b*	CR
C=1	10.5511	94%
C=10	15.1398	96%
C=100	11.1075	92%

懲罰權重 C 控制最大化分離邊界與最小化訓練錯誤的權衡，小 C 有更寬的邊界，允許一些訓練資料被分錯，大 C 則更重視避免訓練錯誤，導致邊界變窄。而 $C=100$ 時，可以發現有多個 α 達到上限，代表模型不惜一切去處理這些較困難訓練點，造成 overfitting，因此 CR 有明顯下降。

Part 2: RBF kernel-based SVM

```
C = 10.0, sigma = 5.0
Alpha sum = 193.7708
alpha =
[10.      8.9618 10.      0.      10.      0.      10.      0.      0.
 0.      0.      0.      0.      10.      0.      0.      8.9618 0.
 8.9618 0.      10.      0.      10.      0.      0.      0.      10.
 0.      6.5942 0.      0.      10.      0.      0.      0.      10.
 10.      0.      10.      0.2913 0.      10.      0.      0.      10.
 0.      10.      0.      10.      0.      ]
b* = 0.0678
CR = 90.0%
```

```
C = 10.0, sigma = 1.0
Alpha sum = 76.2552
alpha =
[ 0.      0.      8.8906 0.      0.      0.      10.      0.3464 0.
 0.      0.      0.      0.      0.      0.      0.      0.      0.
 0.      0.      10.      0.      8.8906 0.      0.      0.      8.1181
 0.      0.      0.      0.      10.      0.      0.      0.      0.
 0.      0.      0.      0.      0.      0.      0.      0.      10.
 0.      0.0094 0.      10.      0.      ]
b* = -0.107
CR = 94.0%
```

```
C = 10.0, sigma = 0.5
Alpha sum = 62.7531
alpha =
[ 0.      0.      5.9852 0.      0.      0.      5.3969 1.0033 0.
 0.      0.      3.006 0.      0.      0.      0.      0.      0.
 0.      0.      10.      0.      5.9852 0.      0.      0.2549 0.
 0.      0.      0.      0.      10.      0.2933 0.      0.1434 0.
 0.      0.      0.      0.      0.      0.      0.      0.5831 10.
 0.      0.1012 0.0007 10.      0.      ]
b* = -0.2376
CR = 94.0%
```

```
C = 10.0, sigma = 0.1
Alpha sum = 36.0576
alpha =
[0.2801 0.3292 1.2411 0.3631 0.0704 0.7028 0.7071 1.0221 0.0397 0.8669
 1.0131 1.0463 0.2517 0.2801 1.145 0.1056 0.3292 0.9249 0.3292 0.9196
 2.5408 0.3631 1.2411 1.0053 0.9109 0.5211 0.1937 0.7048 0.4102 0.1378
 0.415 1.0583 0.8405 0.7712 0.5245 0.537 0.7111 0.7242 0.      0.7778
 0.7622 0.5161 0.5396 0.7948 2.3432 0.6959 0.6502 0.6137 2.2924 0.4936]
b* = -0.1594
CR = 88.0%
```

```
C = 10.0, sigma = 0.05
Alpha sum = 42.7544
alpha =
[0.5377 0.3213 0.6269 0.5453 0.9401 0.9632 1.0929 1.1103 0.9401 1.0907
 1.1103 1.1105 0.9579 0.5377 1.1106 1.0552 0.3213 0.9809 0.3213 1.093
 1.2539 0.5453 0.6269 1.093 1.0909 0.7834 0.783 0.8737 0.7831 0.8414
 0.8574 0.8898 0.8894 0.8891 0.7834 0.692 0.889 0.8891 0.6734 0.8893
 0.8893 0.7834 0.8733 0.8893 1.0591 0.8737 0.7977 0.8734 1.0587 0.8731]
b* = -0.1106
CR = 82.0%
```

RBF SVM	b^*	CR
$\sigma = 5$	0.0678	90%
$\sigma = 1$	-0.1070	94%

$\sigma = 0.5$	-0.2376	94%
$\sigma = 0.1$	-0.1594	88%
$\sigma = 0.05$	-0.1106	82%

根據核函數公式可知，較大的 σ 會使次方項 ≈ 0 ，核函數值 ≈ 1 ，代表一個點的影響範圍廣，遠處的點也會被視為相似，邊界會趨於線性。此外，比較 linear SVM $C=10$ 可發現， $\sigma=5$ 的準確率低很多，可知此邊界對於這組數據來說太簡單，造成了 underfitting。而 σ 太小，核函數值 ≈ 0 ，代表影響範圍很窄，只有非常近的点才會被視為相似，因此容易導致 overfitting，如 $\sigma=0.1, 0.05$ 時 CR 明顯下降。

Part 3: Polynomial kernel-based SVM

```
C = 10.0, p = 1
Alpha sum = 74.4186
alpha =
[ 0.      0.      8.6047  0.      0.      0.      10.      0.      0.
  0.      0.      0.      0.      0.      0.      0.      0.      0.
  0.      0.     10.      0.      8.6047  0.      0.      0.      7.2093
  0.      0.      0.      0.     10.      0.      0.      0.      0.
  0.      0.      0.      0.      0.      0.      0.      0.     10.
  0.      0.      0.     10.      0.      ]
b* = 13.838
CR = 96.0%
```

```
C = 10.0, p = 2
Alpha sum = 54.1767
alpha =
[ 0.      0.      3.8103  0.      0.      0.      9.4678  0.      0.
  0.      0.      0.      0.      0.      0.      0.      0.      0.
  0.      0.     10.      0.      3.8103  0.      0.      0.      0.
  0.      0.      0.      0.     10.      0.      0.      0.      0.
  0.      0.      0.      0.      0.      0.      0.      0.     10.
  0.      0.      0.      7.0884  0.      ]
b* = 12.1033
CR = 94.0%
```

```
C = 10.0, p = 3
Alpha sum = 52.3055
alpha =
[ 0.      0.      4.2544  0.      0.      0.      7.3333  0.      0.
  0.      0.      0.      0.      0.      0.2827  0.      0.      0.
  0.      0.     10.      0.      4.2544  0.028  0.      0.      0.
  0.      0.      0.      0.     10.      0.      0.      0.      0.
  0.      0.      0.      0.      0.      0.      0.      0.     10.
  0.      0.      0.      6.1528  0.      ]
b* = -7.8557
CR = 94.0%
```

```
C = 10.0, p = 4
Alpha sum = 29.8843
alpha =
[ 0.      0.      2.1557  0.      0.      0.      0.      0.      0.
  0.      0.      0.      0.      0.      0.6307  0.      0.      0.
  0.      0.     10.      0.      2.1557  0.      0.      0.0649  0.
  0.      0.      0.      0.      5.5418  0.      0.      0.      0.
  0.      0.      0.      0.      0.      0.      0.      0.      3.3419
  0.      0.      0.      5.9935  0.      ]
b* = -3.0219
CR = 94.0%
```

```

C = 10.0, p = 5
Alpha sum = 21.9684
alpha =
[ 0.    0.    0.1508  0.    0.    0.    0.    0.
 0.3729  0.    0.    0.    0.    0.3098  0.    0.
 0.    0.    10.    0.    0.1508  0.    0.    0.
 0.    0.    0.    0.    4.5176  0.    0.    0.
 0.    0.    0.    0.    0.1866  0.    0.    0.
 0.    0.    0.    6.2799  0.    ]
b* = 56.1991
CR = 88.0%

```

Poly SVM	b*	CR
p = 1	13.838	96%
p = 2	12.1033	94%
p = 3	-7.8557	94%
p = 4	-3.0219	94%
p = 5	56.1991	88%

多項式核函數的參數 p 決定決策邊界的複雜度， $p=1$ 視為線性核函數， $p=2$ 可以產生曲線的邊界，更高階的時候會產生更複雜的多彎曲邊界，能擬合訓練資料中微小的波動和雜訊，容易導致 overfitting，如 $p=5$ 時 CR 掉到只有 88%。

Part 4: Discussion and results presenting (最後頁為不同組合下的作圖)

1. Linear SVM 與 kernel-based SVM 所訓練的 hyperplane 有何差異？

Linear SVM: 其 hyperplane 永遠是一直線，不論懲罰權重 C 如何變化，決策邊界和 margin 都保持直線，只能改變直線的斜率和截距與 margin 的寬窄，故其靈活性有限，僅能處理線性可分的數據。

Kernel-based SVM: 其 hyperplane 在原始的 2 維空間中是非線性的(曲線)，使 model 可以學習較複雜的數據，並將數據投影到高維度空間，來分離線性不可分的數據。其靈活性高，而 hyperplane 的確切形狀則根據核參數決定，RBF 的 σ 或 polynomial 的 p ，將 hyperplane 從直線到平滑曲線，甚至到複雜扭曲的形狀。

2. 隨著 kernel parameter 的改變，RBF kernel 與 polynomial kernel 所訓練的 hyperplane 可能有什麼變化？其與分類率的變化有何關聯？請嘗試解釋之。

RBF kernel (parameter: σ) σ 決定了 RBF kernel function 的寬度

1. Hyperplane 的變化

- 大 σ ($=5$): 影響範圍大，會趨近於一個線性核函數，決策邊界會非常平滑。
- 中 σ ($=1, 0.5$): 影響範圍適中，決策邊界為平滑的非線性曲線。
- 小 σ ($=0.1, 0.05$): 影響範圍很窄，使得邊界變得非常複雜、扭曲。

2. 與分類率的關聯

- 大 σ ($=5$): 模型太簡單導致 underfitting，無法取得 data 的非線性特性，CR 偏低(90%)。

- 中 $\sigma (=1, 0.5)$: 模型達到最佳複雜度。
- 小 $\sigma (=0.1, 0.05)$: 當 σ 變小時，所有訓練資料點都變成了 SV，模型開始學習 training data 的雜訊，導致 generalization performance 顯著下降，CR 分別降至 88% 和 82%。

Polynomial kernel (parameter: p) p (degree) 決定了決策邊界的階數(複雜度)

1. Hyperplane 的變化

- 低 p (=1,2): 邊界是線性的或簡單的二次曲線(在這仍近似線性)。
- 中 p (=3,4): 邊界為明憲的非線性曲線，如 p=3 為橢圓形，p=4 時更不規則。
- 高 p (=5): 邊界高度扭曲，來擬合特定的訓練資料點。


2. 與分類率的關聯

- p = 1: 即為線性模型，沒有 mapping，並達到分類率(96%)，代表此數據基本上是線性可分。
- p = 2,3,4: 有些微的 overfitting 產生，因模型開始 fitting 一些 training set 的特性，導致泛化能力些許下降，分類率降至 94%。
- p = 5: 模型過度複雜，明顯 overfitting，決策邊界遷就少數的 SV，進而導致泛化能力明顯下降，CR 降到 88%。






3. 設定 kernel parameter 時，是否有方法避免 hyperplane 過度擬合(overfitting)的現象發生?若有請詳細討論。

可以採用格子搜尋法並搭配 K-fold cross validation 來驗證各參數設定對於資料的泛化能力。先定義參數網格的搜索範圍，並對格子中的每一種組合，都在 training set 上進行 k 次的 k-fold CV，計算準確率的平均值，代表該組參數的泛化性，記錄所有組合所得到的平均準確率，選擇最高分類率的參數組合。若 grid 很大，可以考慮 early stopping 的策略來加速搜索，以 RBF 為例，當準確率持續降低時，代表模型正往 overfitting 的方向發展，故應停止搜索 $\sigma=0.05$ 或更小的值。此外，適當的資料前處理，如特徵選擇來去除無關特徵的干擾，亦可增加模型訓練的效率。

Linear:



RBF:



Polynomial:

