

Part1. Sequential Forward Selection, SFS

透過 SFS 與 LDA+2-fold CV 的 highest validated balanced accuracy 為 **96.28%**，並選取了 7 個特徵。從結果來看可以看到在 subset size 為 1~5 的時候 acc 大幅上升，細微提升至 subset size = 7 後則開始緩緩下降，代表說加入更多特徵會讓 balanced accuracy 開始下降，overfit 產生。

```
SFS Step 1: Select feature idx=27 name='worst concave points', Acc = 0.8984
SFS Step 2: Select feature idx=20 name='worst radius', Acc = 0.9237
SFS Step 3: Select feature idx=21 name='worst texture', Acc = 0.9364
```

圖 1. 前三筆 highest validated balanced accuracy

```
SFS optimal (size): 7
SFS optimal subset (index, name):
 27: worst concave points
 20: worst radius
 21: worst texture
 23: worst area
 28: worst symmetry
 14: smoothness error
  8: mean symmetry
SFS optimal accuracy = 0.9628
SFS 執行時間: 1.7617 秒
```

圖 2. SFS 最佳子特徵及數量




圖 3. SFS 準確率折線圖

Part2. Fisher's Criterion

費雪法結合 LDA 所達到的 highest validated balanced accuracy 為 **94.49%**，低於 SFS，並選取了 **28** 個特徵。除了第一個子特徵的最高準確率，其餘皆有達到 90% 以上，且執行時間明顯比 SFS 快許多。

```
Fisher Step 1: Add feature idx=27 name='worst concave points', Acc = 0.8984
Fisher Step 2: Add feature idx=22 name='worst perimeter', Acc = 0.9180
Fisher Step 3: Add feature idx= 7 name='mean concave points', Acc = 0.9142
```

圖 4. 前三筆 highest validated balanced accuracy

```
Fisher optimal (size): 28
Fisher optimal subset (index, name):
27: worst concave points
22: worst perimeter
7: mean concave points
20: worst radius
2: mean perimeter
0: mean radius
23: worst area
6: mean concavity
3: mean area
26: worst concavity
5: mean compactness
25: worst compactness
10: radius error
12: perimeter error
13: area error
21: worst texture
1: mean texture
24: worst smoothness
17: concave points error
28: worst symmetry
4: mean smoothness
8: mean symmetry
29: worst fractal dimension
15: compactness error
16: concavity error
19: fractal dimension error
14: smoothness error
9: mean fractal dimension
Fisher optimal accuracy = 0.9449
Fisher 執行時間: 0.2035 秒
```

圖 5. Fisher's Criterion 最佳子特徵及數量




圖 6. Fisher's Criterion 準確率折線圖

Part3. Discussion and results presneting

1. Sequential Forward Selection 和 Fisher's Criterion 分別屬於 Filter-based 和 Wrapper-based 中的何種特徵篩選方法?

Sequential Forward Selection需要依賴分類器(如LDA)，因為它在每一步選特徵時，都必須利用分類器在不同特徵組合上的分類率來判斷是否加入某個特徵。也就是說，特徵的好壞完全取決於分類器的實際效能。因此，SFS屬於 Wrapper-based method，計算量較大，但能找到最適合的特徵組合。

Fisher's Criterion是利用每個特徵的within-class scatter與between-class scatter所計算出的Fisher Score來衡量其辨識能力，並根據score對所有特徵進行排序。整個過程完全不依賴任何分類模型，只根據資料本身的統計特性進行評估。因此，Fisher's Criterion屬於Filter-based method，計算快速，且不會考慮特徵間的互動。

2. 一般來說 Filter-based 和 Wrapper-based 各有什麼性質或優缺點？

Filter-based Method，不依賴任何機器學習模型，直接利用資料的統計特性(如相關性、變異數)來幫特徵打分數，分數高的就留下。其優缺點如下：

優點

1. 效率高：不需要訓練模型，計算量很小，能快速找到較佳特徵子集合。
2. 計算複雜度低：通常基於統計指標(如Fisher score)評估特徵，計算量遠低於wrapper方法，並且較容易實作。
3. 泛化性高：篩選結果獨立於模型，選出來的特徵可以給任何分類器使用。

缺點

1. 不考慮特徵間的相關性：僅評估單一特徵的重要性，沒有考慮到多個特徵的joint probability，所以可能無法找出真正最佳的特徵組合。
2. 容易忽略弱但關鍵的特徵(weak features)：有些特徵單獨看很弱，但跟別人搭配時很強，這類特徵容易被提早淘汰。
3. 找出的特徵組合不一定最適合特定分類器：因為沒有考慮分類模型的特性，因此其選出的特徵不一定能使某個分類器的準確率達到最佳。

Wrapper-based method直接使用分類器的預測準確率來評估不同的特徵組合，因此能針對特定分類器，在目前的資料下找出最能提升其準確率的特徵集合。其優缺點如下：

優點

1. 可獲得較佳的特徵組合：因為它考慮到特徵之間的joint probability，比Filter方法更容易找到真正能提升分類效能的特徵集合。
2. 可適應不同模型：Wrapper方法與分類器綁定，因此能依據不同模型的特

性來選擇最適合該模型的特徵。

缺點

1. 計算複雜度極高：需要反覆訓練模型來測試各種組合(多為greedy approach，如 SFS)，使得計算時間隨特徵數量呈指數級增加。

3. 在本次作業的結果中是否有展現出跟上一題你的回答有一致的現象呢？不管是否一致皆請你試著討論與分析原因。

根據 Fisher's Criterion 與 SFS 所得到的最佳特徵組合跟分類率皆與上述分析一致。可分為以下幾點分析

1. 最佳特徵數目

Fisher(Filter-based)找到了 28 個特徵的最大分類率，反映其不考慮特徵冗餘性、容易保留大量特徵的特性。

SFS(Wrapper-based)則在第 7 個特徵即達到最佳性能，顯示其能有效利用分類器資訊找出最小且最有效的特徵組合。

2. 最佳分類率

Fisher(Filter-based)不考慮模型，只看各特徵本身的分群能力，因此最佳性能通常較弱(94.49%)。

SFS(Wrapper-based)直接把分類器效能當評分標準，因此最終得到的特徵組合有較高的準確率(96.28%)。

3. 執行時間

SFS 的訓練次數為 $2 \times (30) \times (30+1)/2 = 930$ 次，複雜度為 $O(d^2)$ ，訓練時間為 1.7617 秒，而 Fisher 為 $2 \times 30 = 60$ 次，複雜度為 $O(d)$ ，時間為 0.2035 秒，其訓練數量遠小於 SFS，可以節省許多運算時間。